AB2 - Ciência de Dados

Nome: Lucas Albuquerque Lisboa;
Matrícula: 18110495;
Professor: Bruno Pimentel

1. **Sobre Árvores de Decisão, descreva três vantagens de usar esse método. (1 ponto)**
   Resposta:
   Algumas das vantagens do uso das árvores de decisão consistem:
   - Na fácil implementação, sendo, em essência, a estrutura de dados que dá nome à técnica;
   - Na baixa complexidade, pois se a árvore estiver bem balanceada, após a construção dela, o custo para a solução será a altura;
   - Bastante visual, permitindo boa explicação e entendimento para pessoa que, inclusive, não são da área de computação;
   - Na maioria das vezes, é possível expandir a árvore com novos nós sem alterações significativas.

2. **Mostre como o classificador Random Forest pode ser usado para extração de informações a partir de um conjunto de dados. (1 ponto)**
   Resposta:
   O classificador Random Forest é um tipo de Método Ensemble, isto é, uma estratégia na qual um conjunto de modelos são criados para possibilitar, ao final, a escolha do melhor. Para isso, o Random Forest cria diversos modelos diferentes de árvores de decisão, cada um com amostragem aleatória da base de treino e da base de teste, permitindo que as árvores geradas possuam baixa correlação entre si. Isso permite verificar quais características do conjunto de dados possuem mais relevância para tomada de decisão e influenciam mais no resultado final.

3. **De que forma modelos para séries temporais podem ajudar na descoberta de informação? (2 pontos)**
   Resposta:
   Uma série temporal consiste numa sequência de valores distribuídos cronologicamente num determinado intervalo de tempo, distribuídos, em geral, de maneira equidistante entre si. Isso permite verificar o comportamento das características analisadas ao longo do tempo, podendo observar a tendência e os impactos dos eventos no período. Um exemplo prático disso é, ao plotar o gráfico correspondente, verificar a existência de picos e quedas pontuais em determinados momentos, sendo possível buscar nos pontos em questão os motivos que geraram tais acontecimentos. Dessa forma, de posse das novas informações, pode-se tomar a decisão que intensifique os picos e minimize as quedas (em caso de um função de maximização), ou minimize os picos e intensifique as quedas (em caso de um função de minimização). Além disso, é possível verificar a tendência a longo prazo, de forma

a tentar estipular os resultados do período subsequente ao analisado, permitindo uma maior organização por parte dos envolvidos.

4. **Mostre como um sistema usando a abordagem de Meta-aprendizado pode ajudar:**
    a. **Empresas (1 ponto)**
    b. **Usuários (1 ponto)**

    Resposta:

    O conceito de Meta-aprendizado consiste na elaboração de um modelo genérico que seja possível instanciar algoritmos adequados para solução de problemas semelhantes. Isso ocorre mediante a combinação de padrões previamente estabelecidos, como o domínio do problema, métricas estatísticas, especificações de parâmetros, complexidade associada, entre outros. Para as empresas, isso permite reduzir o custo e otimizar o tempo, pois, a partir da formulação inicial, é possível replicar para os problemas futuros. Já para os usuários, em especial os cientistas de dados, é possível fazer correlações entre os problemas, replicar soluções sem a necessidade de programação direta e melhorar a explanação de seus resultados.

5. **Descreva um sistema de Meta-aprendizado (explicando a construção de meta-características, meta-base e meta-aprendiz) usado para recomendar hiperparâmetros do modelo ARIMA. (2 pontos)**

    Resposta:

    A construção de um sistema Meta-aprendizado, mediante o modelo ARIMA, ocorre em decorrência de quatro etapas:

    1. Especificação de uma Classe Geral de Modelos: É selecionado um conjunto de datasets e extraído suas meta-características.
    2. Identificação de um Modelo: É testado a permutação de hiperparâmetros em cada dataset selecionado e escolhido o conjunto com melhor acurácia
    3. Estimação do Modelo: Aqui, é montada a meta-base, de modo a colocar as meta-características extraídas em cada linha dos datasets selecionados, enquanto na última coluna são inseridos os hiperparâmetros obtidos;
    4. Diagnóstico do Modelo Ajustado: Neste ponto, é construído o meta-aprendiz, sendo composto de um classificador, de maneira que seja selecionado um dataset desconhecido pelo sistema, dando como saída o melhor conjunto de hiperparâmetros. Sendo validado, os hiperparâmetros podem ser incorporados; caso não, o sistema para etapa de Identificação de um Modelo.

6. **Sobre Visualização de Dados, descreva cada uma das seis etapas recomendadas para uma boa apresentação de resultados. (2 pontos)**

    Resposta:

    As seis etapas para realizar a Visualização de Dados consistem em:

    1. Entender o Contexto dos Dados: Antes de arquitetar o que será apresentado, é importante entender o que está sendo tratado. Para isso, é preciso realizar uma

análise exploratória (encontrar as informações relevantes) e uma análise explanatória (analisar o que e como comunicar), pensando sempre no público-alvo do trabalho;

2. Escolher um Visual Eficaz em Transmitir a Informação: Aqui é preciso pensar em estratégias visuais que facilitem a explicação. Alguns pontos a serem observados aqui é: que tipo de gráfico usar (linhas, barras, pontos, entre outros)? Qual escala é a melhor a ser usada?, entre outros;
3. Eliminar a Saturação: Neste momento, é feito uma limpeza de informações que possam poluir as imagens obtidas e distrair a atenção do público, como por exemplo: remover linhas desnecessárias, abreviar nomes, ajustar legenda, entre outros;
4. Focar a Atenção onde é mais Importante: Diante de uma representação com mais de uma informação, é preciso saber destacar o que é importante para ser passado ao público. Dessa forma, utilizar cores diferentes nos valores-chaves, aumentar o tamanho da fonte, entre outras estratégias auxiliam a apontar o mais importante a ser constatado;
5. Pensar como um Design: Pensar em elementos mais sutis da sua representação também é importante para facilitar o entendimento: analisar se a fonte usada é legível, se as cores usadas estão adequadas, se o espaçamento está equilibrado, são pontos que evitam a dispersão de atenção de quem visualizará tal resultado;
6. Contar uma História: Organizar uma sequência lógica de ideias e uma maneira de interagir com o público é o passo final para realizar uma boa visualização dos dados, pois permite maior conexão com o que está sendo dito.